

PRACA PROJEKTOWA

Wielowymiarowa Analiza Danych

Wielowymiarowa analiza danych i prognozowanie ryzyka w sektorze ubezpieczeń zdrowotnych przy użyciu technologii Business Intelligence

Pracę wykonali:

Magdalena Stanek (nr albumu: 176862)

Agnieszka Słapińska (nr albumu: 176859)

Kierunek: Inżynieria i Analiza Danych

Grupa: 6 (2025/26-L)

Opiekun pracy:

mgr inż. Joanna Rysz

Rzeszów 2026

Spis treści

1. Cel projektu.....	3
2. Importowanie danych.....	3
3. Opis danych i przygotowanie środowiska.....	5
4. Projekt fizyczny hurtowni danych (Schemat Gwiazdy).....	5
5. Architektura procesów ETL (SSIS)	9
5.1 ETL 1 – Wymiar Pacjenta (Dim_Patient)	9
5.2 ETL 2 – Wymiar Medyczny (Dim_Medical).....	12
5.3 ETL 3 – Wymiar Profilu (Dim_Profile).....	13
5.4 ETL 4 – Wymiar Ubezpieczeń (Dim_Coverage).....	14
5.5 ETL 5 – Proces zasilania centralnej tabeli faktów (Fact_Insurance)	16
5.6 Podsumowanie etapu ETL.....	18
6. Kostka OLAP	23
6.1 Wstęp: Przygotowanie środowiska pracy.....	23
6.2 Definiowanie warstwy analitycznej, miar podstawowych oraz agregacji MDX.....	30
6.3 Hierarchie wymiarów	34
6.4 Scenariusze KPI (Kluczowe Wskaźniki Efektywności).....	36
6.4.1 Scenariusz 1: Kontrola rentowności polis (KPI_Sredni_Koszt)	37
6.4.2 Scenariusz 2: Prewencja i ocena ryzyka (KPI_Srednie_BMI)	38
6.4.3 Scenariusz 3: Ocena wolumenu sprzedaży (KPI_Liczba_Pacjentow)	38
6.4.4 Scenariusz 4: Stabilność demograficzna portfela (KPI_Sredni_Wiek).....	39
7. Data mining.....	40
7.1 Modelowanie Algorytmem Drzew Decyzyjnych (Microsoft Decision Trees)	42
7.2 Grupowanie Pacjentów – Analiza Skupień (Microsoft Clustering).....	45
7.3 Analiza Wrażliwości i Predykcja Siecią Neuronową (Microsoft Neural Network).....	48
7.4 Integracja Wyników Predykcyjnych ze Strukturą Wielowymiarową Kostki OLAP ...	50
8. Wizualizacje w Power BI.....	54
8.1 Raport 1: Walidacja Modeli Predykcyjnych Sztucznej Inteligencji i Trendy Wieków... 56	
8.2 Raport 2: Analiza Struktury Finansowej i Wpływu Obciążeń Chorobowych	58
8.3 Raport 3: Koncentracja Ryzyka Fizjologicznego i Analiza Geograficzno-Matrycowa	60
8.4 Raport 4: Wielowymiarowa analiza struktury operacyjnej i profilu zachorowalności populacji.....	61

1. Cel projektu

Celem niniejszego etapu projektu było zaprojektowanie i wdrożenie kompleksowego procesu zasilania hurtowni danych (ETL – Extract, Transform, Load) dla danych z branży ubezpieczeniowej. Głównym założeniem było oczyszczenie, przekształcenie i załadowanie surowych danych do wielowymiarowego modelu bazy danych (gwiazdy/płatka śniegu). Tak przygotowana architektura stanowi solidny fundament pod budowę Kostki OLAP oraz późniejsze wykorzystanie algorytmów Data Mining do predykcji opłat ubezpieczeniowych.

2. Importowanie danych

Pierwszym krytycznym etapem realizacji projektu było przeprowadzenie procesu ekstrakcji danych ze zbioru źródłowego oraz ich fizyczna migracja do relacyjnego środowiska bazodanowego SQL Server. Dane wejściowe dystrybuowane były w postaci surowego, płaskiego pliku tekstowego o rozszerzeniu CSV (*insurance_dataset.csv*), zawierającego wolumen ponad miliona unikalnych rekordów pacjentów. Ze względu na specyfikę plików płaskich, struktura ta pozbawiona była silnego typowania kolumn oraz jakichkolwiek reguł spójności, co wymagało przeprowadzenia zaawansowanego procesu profilowania danych (*Data Profiling*) jeszcze przed zainicjowaniem właściwych transformacji ETL.

W celu wprowadzenia surowych danych do struktur serwera bazodanowego wykorzystano dedykowane narzędzie **SQL Server Import and Export Wizard**. W fazie konfiguracji schematu wejściowego (*Modify Columns*) zidentyfikowano wysoki stopień zaszumienia informacji oraz brak optymalizacji pamięciowej pierwotnych atrybutów. Narzędzie źródłowe domyślnie interpretowało wszystkie kolumny jako tekstowe ciągi znaków o zmiennej długości (*nvarchar(50)*). Zaakceptowanie takiego schematu uniemożliwiłoby późniejsze wykonywanie jakichkolwiek operacji agregujących (takich jak sumowanie czy wyliczanie średnich) oraz drastycznie obniżyłoby wydajność pamięciową struktur dyskowych.

W związku z tym przeprowadzono restrykcyjną redefinicję i optymalizację typów danych na poziomie wejścia:

Atrybuty ściśle numeryczne o niskiej ziarnistości i ograniczonym przedziale wartości, takie jak wiek pacjenta (*age*) oraz liczba posiadanych dzieci (*children*), zostały zmapowane na typ całkowitoliczbowy o minimalnej alokacji bajtowej – **tinyint**.

Kolumny opisujące cechy fizjologiczne oraz wskaźniki finansowe, w szczególności wskaźnik masy ciała (*bmi*) oraz sumaryczne koszty leczenia i opłaty ubezpieczeniowe (*charges*),


przekonwertowano na zmiennoprzecinkowy typ danych **float** (bądź docelowo o wysokiej precyzji decimal). Krok ten był bezwzględnie wymagany, aby silnik relacyjny oraz późniejsza kostka OLAP mogły wykonywać zaawansowane operacje matematyczne.

Pola flagowe o charakterze binarnym, takie jak status nałogu tytoniowego (smoker), przetłumaczono na typ bitowy **bit** (wartości logiczne 0 lub 1), co pozwoliło na optymalne upakowanie informacji w strukturze stron bazodanowych.

Pozostałe atrybuty o charakterze opisowym i słownikowym, w tym płeć (gender), lokalizacja geograficzna (region), historia chorób (medical_history), zawód (occupation) oraz poziom ochrony polisy (coverage_level), zostały ujednolicone do bezpiecznego standardu łańcuchów tekstowych **nvarchar(50)**.

W celu zabezpieczenia potoku migracyjnego przed awariami wynikającymi z występowania anomalii w strukturze pliku płaskiego (np. pustych wierszy lub niedozwolonych znaków nie-numerycznych w polach liczbowych), w kreatorze skonfigurowano regułę raportowania błędów na poziomie pojedynczych wierszy (*Row granularity of error reporting*). Logika ta zapewnia stabilność transakcyjną: w przypadku napotkania rekordu uszkodzonego, system automatycznie izoluje wadliwy wiersz i przekierowuje go do logu diagnostycznego, nie powodując przerywania i wyłożenia procesu importu dla pozostałego miliona poprawnych rekordów.

Zaimplementowany w ten sposób import danych pozwolił na utworzenie i zasilenie tabeli buforowej w dedykowanej warstwie przejściowej (**Staging Area**). Tabela ta stała się punktem odcięcia od pliku płaskiego – od tego momentu wszystkie transformacje oczyszczania danych, eliminacji duplikatów i standaryzacji językowej realizowane w pakietach SSIS były wykonywane bezpośrednio na zoptymalizowanym pod kątem operacji I/O silniku relacyjnym, co stanowiło kluczowy fundament pod budowę wydajnej hurtowni danych.



3. Opis danych i przygotowanie środowiska

Dane wejściowe pochodzą z pliku tekstowego insurance_dataset.csv i zawierają informacje o pacjentach/klientach (m.in. wiek, płeć, BMI, status palacza, historia medyczna, region, zawód, poziom ubezpieczenia oraz koszty leczenia).

W celu zapewnienia najwyższej jakości danych w hurtowni (Data Quality), przed budową procesów ETL przygotowano w środowisku SQL Server Management Studio (SSMS) strukturę pomocniczą:

- Tabela_Bledow: Centralne repozytorium na odrzucone i błędne wiersze.
- Tabele słownikowe: Słownik_Zawodow, Słownik_Regionow oraz Słownik_Ubezpieczen, wykorzystywane do autokorekty i walidacji danych tekstowych.

Zmodyfikowano typy i długości kolumn (np. powiększenie kolumny Smoker), aby zminimalizować ryzyko obcięcia danych (Truncation) podczas procesu ładowania.

4. Projekt fizyczny hurtowni danych (Schemat Gwiazdy)

Architektura Staging Area (Obszar przejściowy)

W celu optymalizacji procesu ekstrakcji (Extract) zaimplementowano obszar przejściowy w postaci tabeli Staging_Insurance. Pełni ona rolę bufora dla surowych danych pobieranych bezpośrednio z płaskiego pliku .csv. Zastosowanie tabeli stagingowej pozwoliło na zminimalizowanie operacji wejścia/wyjścia na pliku źródłowym – dane są do niej ładowane jednorazowo, a następnie kolejne procesy transformacyjne (ETL 2, 3 i 4) odczytują je już bezpośrednio z silnika bazy danych SQL Server. Znacząco zwiększyło to wydajność i stabilność całego przepływu.

Przed przystąpieniem do budowy procesów ETL, w środowisku SQL Server zaprojektowano i zaimplementowano fizyczny model hurtowni danych oparty na **schemacie gwiazdy (Star Schema)**. Zastosowanie tej architektury zapewnia optymalną wydajność zapytań analitycznych oraz przejrzystość modelu dla systemów Business Intelligence.

W ramach modelu utworzono następujące obiekty:

Tabele Wymiarów (Dimensions):

Dim_Patient: Przechowuje dane demograficzne (wiek, płeć, BMI, status palacza).

Dim_Medical: Zawiera informacje o historii medycznej i częstotliwości ćwiczeń.

Dim_Profile: Grupuje dane o lokalizacji (region) oraz profilu zawodowym.

Dim_Coverage: Definiuje dostępne poziomy ochrony ubezpieczeniowej.

Tabela Faktów (Fact Table):

Fact_Insurance: Centralna tabela modelu, która łączy wszystkie wymiary za pomocą kluczy obcych (FOREIGN KEY). Przechowuje ona miarę ilościową Charges (koszty), która jest głównym obiektem późniejszej analizy i predykcji.

Każda tabela wymiaru została wyposażona w klucz główny typu IDENTITY (Surogatny Klucz Główny), co uniezależnia hurtownię od zmian w systemach źródłowych i ułatwia zarządzanie historią danych.

Object Explorer

Connect

DESKTOP-IFD8LT5\WAD (SQL Server 15)

- Databases
 - System Databases
 - Database Snapshots
 - Projekt
 - Database Diagrams
 - Tables
 - System Tables
 - FileTables
 - External Tables
 - Graph Tables
 - dbo.insurance
 - Views
 - External Resources
 - Synonyms
 - Programmability
 - Service Broker
 - Storage
 - Security
 - Security
 - Server Objects
 - Replication
 - PolyBase
 - Always On High Availability
 - Management
 - Integration Services Catalogs
 - SQL Server Agent (Agent XPs disabled)
 - XEvent Profiler

SQLQuery2.sql - DE...D8LT5\Student (65))*

```
-- Tabela Wymiaru: Pacjent
CREATE TABLE Dim_Patient (
    PatientKey INT IDENTITY(1,1) PRIMARY KEY,
    Age INT,
    Gender NVARCHAR(50),
    BMI FLOAT,
    Children INT,
    Smoker NVARCHAR(10)
);

-- Tabela Wymiaru: Lokalizacja i Praca
CREATE TABLE Dim_Profile (
    ProfileKey INT IDENTITY(1,1) PRIMARY KEY,
    Region NVARCHAR(50),
    Occupation NVARCHAR(100)
);

-- Tabela Wymiaru: Historia Medyczna
CREATE TABLE Dim_Medical (
    MedicalKey INT IDENTITY(1,1) PRIMARY KEY,
    Medical_History NVARCHAR(100),
    Family_Medical_History NVARCHAR(100),
    Exercise_Frequency NVARCHAR(50)
);

-- Tabela Wymiaru: Poziom ubezpieczenia
CREATE TABLE Dim_Coverage (
    CoverageKey INT IDENTITY(1,1) PRIMARY KEY,
    Coverage_Level NVARCHAR(50)
);

-- Tabela Faktów
CREATE TABLE Fact_Insurance (
    FactKey INT IDENTITY(1,1) PRIMARY KEY,
    PatientKey INT FOREIGN KEY REFERENCES Dim_Patient(PatientKey),
    ProfileKey INT FOREIGN KEY REFERENCES Dim_Profile(ProfileKey),
    MedicalKey INT FOREIGN KEY REFERENCES Dim_Medical(MedicalKey),
    CoverageKey INT FOREIGN KEY REFERENCES Dim_Coverage(CoverageKey),
    Charges FLOAT
);
```

Object Explorer

Connect

DESKTOP-IFD8LT5\WAD (SQL Server 15)

- Databases
 - System Databases
 - Database Snapshots
 - Projekt
 - Database Diagrams
 - Tables
 - System Tables
 - FileTables
 - External Tables
 - Graph Tables
 - dbo.insurance
 - Views
 - External Resources
 - Synonyms
 - Programmability
 - Service Broker
 - Storage
 - Security
 - Security
 - Server Objects
 - Replication
 - PolyBase
 - Always On High Availability
 - Management
 - Integration Services Catalogs
 - SQL Server Agent (Agent XPs disabled)
 - XEvent Profiler

SQLQuery3.sql - DE...D8LT5\Student (55))*

```
-- Tabela tymczasowa (Staging)
CREATE TABLE Staging_Insurance (
    StagingID INT IDENTITY(1,1) PRIMARY KEY,
    age INT,
    gender NVARCHAR(50),
    bmi FLOAT,
    children INT,
    smoker NVARCHAR(50),
    region NVARCHAR(50),
    medical_history NVARCHAR(100),
    family_medical_history NVARCHAR(100),
    exercise_frequency NVARCHAR(50),
    occupation NVARCHAR(100),
    coverage_level NVARCHAR(50),
    charges FLOAT
);
```

100 %

Messages

Commands completed successfully.

Completion time: 2026-04-08T23:13:59.0777045+02:00

Flat File Connection Manager Editor

Connection manager name: Flat File Connection Manager

Description:

General
Columns
Advanced
Preview

Select a file and specify the file properties and the file format.

File name: C:\Users\Student\Desktop\insurance_dataset. Browse...

Locale: Polski (Polska) ☐ Unicode

Code page: 1250 (ANSI - Europa Środkowa)

Format: Delimited


Text qualifier: <none>

Header row delimiter: {CR}{LF}

Header rows to skip: 0

☒ Column names in the first data row


OK Cancel Help





5. Architektura procesów ETL (SSIS)

Proces zasilania hurtowni został podzielony na cztery niezależne, ale połączone sekwencyjnie pakiety Data Flow Task, zarządzane przez nadrzędny przepływ (Control Flow). Całość inicjuje zadanie Execute SQL Task, które przed każdym uruchomieniem procesu opróżnia tabelę błędów (instrukcja TRUNCATE TABLE), zapobiegając w ten sposób dublowaniu się logów z poprzednich sesji.

5.1 ETL 1 – Wymiar Pacjenta (Dim_Patient)








Przepływ ten odpowiada za wczytanie podstawowych danych demograficznych. Wykorzystano w nim następujące transformacje:

- Flat File Source & Sort: Pobranie danych z plików płaskich i ich posortowanie rosnąco po kolumnach age oraz bmi.
- Merge: Złączenie strumieni danych w jeden spójny zestaw. Przed operacją ujednolicono metadane (typ Unicode string [DT_WSTR]), aby uniknąć błędów bufora.
- Lookup: Weryfikacja duplikatów. System sprawdza, czy dany pacjent nie istnieje już w bazie. Wiersze nowe trafiają (wyjściem No Match Output) do głównej tabeli Dim_Patient przez komponent OLE DB Destination, natomiast zduplikowane wiersze są przekierowywane do tabeli odrzutów.

5.2 ETL 2 – Wymiar Medyczny (Dim_Medical)




W tym przepływie zaimplementowano zaawansowaną obsługę błędów na poziomie typów danych.

- **OLE DB Source:** Pobranie surowych danych z tabeli tymczasowej (Staging).
- **Data Conversion:** Przekształcenie formatu kolumn historii medycznej na zgodny ze standardem bazy. Zastosowano tu opcję **Redirect Row** – w przypadku niezgodności formatu, błędny wiersz nie przerywa pracy pakietu, lecz jest kierowany czerwoną strzałką bezpośrednio do **Tabela_Bledow**.
- **Lookup:** Zabezpieczenie przed wpisywaniem powtarzających się historii medycznych. Nowe dane zasilają **Dim_Medical**, a duplikaty dołączają do tabeli błędów.

5.3 ETL 3 – Wymiar Profilu (Dim_Profile)

```
SQLQuery8.sql - DE...D8LT5\Student (53))*  SQLQuery7.sql - DE...D8LT5\Student (57))*
CREATE TABLE Słownik_Regionow (
    Id_Regionu INT IDENTITY(1,1) PRIMARY KEY,
    Nazwa_Regionu NVARCHAR(50)
);
INSERT INTO Słownik_Regionow (Nazwa_Regionu)
VALUES ('southwest'), ('southeast'), ('northwest'), ('northeast');
```




Proces ten realizuje logikę walidacji kaskadowej z wykorzystaniem dwóch komponentów sprawdzających.

- Lookup 2 (Słownik): Weryfikacja wartości tekstowych z kolumny opisującej region. Jeśli region nie występuje w zdefiniowanym wcześniej słowniku w bazie SQL, rekord zostaje uznany za błędny i trafia (wyjściem Error Output) do tabeli błędów.
- Lookup 1 (Duplikaty): Poprawne rekordy są następnie sprawdzane pod kątem unikalności w tabeli Dim_Profile. Podobnie jak w poprzednim kroku, zastosowano tutaj zabezpieczenie przekierowujące ewentualne awarie odczytu bezpośrednio do kosza na błędy. Oczyszczone i unikalne wiersze zasilają wymiar docelowy.

5.4 ETL 4 – Wymiar Ubezpieczeń (Dim_Coverage)


```
SQLQuery9.sql - DE...D8LT5\Student (51))*  SQLQuery8.sql - DE...D8LT5\Student (53))*  SQLQuery7.sql - DE...D8LT5\Student (51))*
CREATE TABLE Sownik_Ubezpieczen (
    Id_Slownika INT IDENTITY(1,1) PRIMARY KEY,
    Poprawny_Poziom NVARCHAR(50)
);

INSERT INTO Sownik_Ubezpieczen (Poprawny_Poziom)
VALUES ('Basic'), ('Standard'), ('Premium');
```



Najbardziej zaawansowany przepływ odpowiadający za inteligentne czyszczenie danych (Data Cleansing) i poprawę literówek wprowadzonych przez użytkowników.

- Fuzzy Lookup (Wyszukiwanie Rozmyte): Algorytm analizuje nazwy ubezpieczeń (oraz zawodów) i na podstawie tabeli referencyjnej Słownik_Ubezpieczeń dobiera najbardziej prawdopodobną, poprawną wartość. Błędne wpisy (np. "Premum" zamiast "Premium") są automatycznie korygowane.
- Derived Column (Kolumna Pochodna): Zaimplementowano wyrażenie warunkowe ISNULL(Poprawny_Poziom) ? coverage_level : Poprawny_Poziom, które chroni przed wstawieniem wartości NULL w przypadku, gdy algorytm rozmyty nie znajdzie żadnego dopasowania.
- Po standaryzacji typów za pomocą Data Conversion, dane przechodzą przez finalny weryfikator Lookup i zasilają wymiar Dim_Coverage, a powtórki trafiają do archiwum błędów.

5.5 ETL 5 – Proces zasilania centralnej tabeli faktów (Fact_Insurance)

Lookup Transformation Editor

This transform enables the performance of simple equi-joins between the input and a reference data set.

General
Connection
Columns
Advanced
Error Output

Specify a data source to use. You can select a table in a data source view, a table in a database connection, or the results of an SQL query.


OLE DB connection manager:
DESKTOP-IFD8LT5\WAD.Projekt New...

☐ Use a table or a view:
[dbo].[Dim_Patient] New...

☒ Use results of an SQL query:
SELECT *, CAST(bmi AS varchar(50)) AS bmi_tekst
FROM Dim_Patient Build Query...
Browse...
Parse Query

Preview...

OK Cancel Help



Ostatnim, najbardziej złożonym pod względem spójności relacyjnej etapem w warstwie integracji danych była implementacja pakietu ETL 5. Przepływ ten odpowiada za ostateczne zasilenie centralnej tabeli faktów Fact_Insurance. Zadaniem tego potoku danych (*Data Flow*) było pobranie surowej miary finansowej (kosztów leczenia) z tabeli przejściowej oraz jednoczesna zamiana naturalnych kluczy biznesowych na sztuczne klucze surogatowe wygenerowane wcześniej w tabelach wymiarów. Proces ten zrealizowano dla wolumenu wynoszącego dokładnie **1 000 000 wierszy**, zachowując pełną integralność referencyjną modelu gwiazdy.

W ramach przepływu zaimplementowano sekwencję następujących po sobie komponentów i transformacji:

- **OLE DB Source (Źródło danych):** Komponent odpowiedzialny za masowe pobranie miliona surowych wierszy bezpośrednio z bazy stagingowej.
- **Data Conversion (Konwersja danych):** Transformacja optymalizacyjna, której zadaniem było ujednolicenie i rzutowanie typów danych dla kluczy biznesowych, tak aby metadane strumienia wejściowego były w 100% kompatybilne z typami indeksowanymi w tabelach słownikowych.
- **Kaskadowy łańcuch transformacji Lookup (Mapowanie kluczy surogatowych):** Aby zmontować kompletny rekord tabeli faktów, strumień danych został przepuszczony sekwencyjnie przez cztery komponenty wyszukiwania referencyjnego, z których każdy odpowiada za odpytanie jednego wymiaru hurtowni i zwrócenie powiązanego klucza głównego:



- **Lookup:** Odpytuje słownik pacjentów (Dim_Patient) i na podstawie dopasowania biznesowego pobiera wygenerowany klucz surogatowy PatientKey.
- **Lookup 1:** Odpytuje wymiar profili socjo-geograficznych (Dim_Profile), mapując dane i zwracając identyfikator ProfileKey.
- **Lookup 2:** Wykonuje zapytanie referencyjne do wymiaru historii chorób i parametrów zdrowotnych (Dim_Medical), dołączając do strumienia klucz MedicalKey.
- **Lookup 3:** Ostatni komponent w łańcuchu, który weryfikuje poziomy polis w tabeli ubezpieczeń (Dim_Coverage) i zwraca ostateczny klucz CoverageKey.

Wszystkie cztery komponenty zostały skonfigurowane tak, aby przetwarzać wyłącznie rekordy poprawnie dopasowane, co dokumentują linie wyjściowe typu **Lookup Match Output**, przesyłające bezstratnie pełne pasmo miliona wierszy z jednego etapu do drugiego.

OLE DB Destination (Miejsce docelowe): Po zebraniu kompletu czterech kluczy surogatowych oraz skorelowanej z nimi miary numerycznej kosztów (Charges), zintegrowany strumień danych jest masowo i wysoce wydajnie utrwalany w docelowej strukturze tabeli faktów Fact_Insurance.

5.6 Podsumowanie etapu ETL

Zaprojektowana architektura w 100% zrealizowała postawione przed nią zadania. Dzięki zastosowaniu transformacji czyszczących, walidacyjnych oraz implementacji "miękkiego" przechwytywania błędów (Redirect Row / Error Output), proces zasilania hurtowni jest w pełni zautomatyzowany i wysoce odporny na uszkodzone dane z plików płaskich. Baza danych została pomyślnie zasilana wymiarami, tworząc środowisko gotowe do implementacji logiki biznesowej, budowy kostki OLAP oraz modeli Data Mining.



Podgląd oczyszczonych danych po procesach ETL

Preview Query Results	
Query result (up to the first 200 rows):	
Coverage...	Coverage_...
0	Premium
1	Premium
2	Premium
3	Standard
4	Standard
5	Basic
6	Basic
7	Standard
8	Basic
9	Basic
10	Premium
11	Premium
12	Standard
13	Basic
14	Basic
15	Basic
16	Basic
17	Basic
18	Standard
19	Premium
20	Basic
21	Basic
22	Premium
23	Basic
24	Standard
25	Premium
26	Premium
27	Basic
28	Basic
29	Premium
30	Basic
31	Basic
32	Standard
33	Standard
34	Basic
35	Standard
36	Basic
37	Premium

Aktywuj system Windows

Przejdź do ustawień, aby aktywować system Windows.

Close

Preview Query Results

Query result (up to the first 200 rows):

ProfileKey	Region	Occupation
0	southeast	Blue collar
1	northwest	White collar
2	southwest	Blue collar
3	northwest	White collar
4	northwest	White collar
5	northeast	Student
6	northeast	Blue collar
7	southeast	Student
8	northeast	Unemployed
9	northeast	Student
10	northwest	Student
11	northwest	Blue collar
12	northwest	Unemployed
13	southeast	Student
14	southwest	White collar
15	southwest	Student
16	northwest	Unemployed
17	southeast	Blue collar
18	southeast	White collar
19	southwest	Unemployed
20	northwest	White collar
21	northeast	Unemployed
22	southeast	White collar
23	northwest	Unemployed
24	southwest	White collar
25	northwest	Student
26	southwest	Student
27	southwest	White collar
28	southwest	White collar
29	southwest	White collar
30	northwest	White collar
31	northeast	Student
32	northeast	White collar
33	northeast	White collar
34	northeast	White collar
35	southwest	Student
36	southwest	Blue collar
37	southeast	Unemployed

Aktywuj system Windows
Przejdź do ustawień, aby aktywować system Windows.

Close

Preview Query Results

Query result (up to the first 200 rows):

MedicalKey	Medical_Hi...	Family_Me...	Exercise_F...
0	Diabetes	None	Never
1	Diabetes	High bloo...	Occasionally
2	None	High bloo...	Occasionally
3	None	Diabetes	Rarely
4	Diabetes	High bloo...	Rarely
5	None	None	Never
6	High bloo...	High bloo...	Never
7	Heart dise...	High bloo...	Rarely
8	None	Diabetes	Occasionally
9	Diabetes	None	Never
10	None	Diabetes	Rarely
11	High bloo...	High bloo...	Occasionally
12	None	Heart dise...	Rarely
13	High bloo...	High bloo...	Frequently
14	Diabetes	High bloo...	Rarely
15	High bloo...	None	Occasionally
16	Diabetes	Heart dise...	Never
17	None	High bloo...	Occasionally
18	None	Diabetes	Frequently
19	None	Diabetes	Frequently
20	Diabetes	None	Occasionally
21	High bloo...	None	Frequently
22	High bloo...	Diabetes	Never
23	Diabetes	None	Occasionally
24	Diabetes	High bloo...	Frequently
25	Heart dise...	None	Rarely
26	Heart dise...	High bloo...	Never
27	None	None	Never
28	High bloo...	Heart dise...	Occasionally
29	High bloo...	Diabetes	Never
30	Heart dise...	High bloo...	Occasionally
31	High bloo...	Diabetes	Frequently
32	Diabetes	Diabetes	Occasionally
33	High bloo...	Heart dise...	Never
34	Diabetes	Heart dise...	Frequently
35	None	Diabetes	Frequently
36	High bloo...	Heart dise...	Occasionally
37	None	Diabetes	Frequently

Aktywuj system Windows
Przejdź do ustawień, aby aktywować system Windows.

Close

Preview Query Results

Query result (up to the first 200 rows):

PatientKey	Age	Gender	BMI	Children	Smoker
0	18	male	18	4	no
1	18	male	18	4	no
2	18	male	18,01	5	no
3	18	female	18,01	5	no
4	18	female	18,01	0	yes
5	18	female	18,01	5	no
6	18	female	18,01	2	no
7	18	male	18,01	2	no
8	18	female	18,01	3	no
9	18	male	18,01	5	no
10	18	female	18,01	5	no
11	18	female	18,01	0	yes
12	18	female	18,01	5	no
13	18	female	18,01	2	no
14	18	male	18,01	2	no
15	18	female	18,01	3	no
16	18	female	18,02	5	yes
17	18	female	18,02	1	no
18	18	female	18,02	0	yes
19	18	male	18,02	5	yes
20	18	female	18,02	5	yes
21	18	male	18,02	1	yes
22	18	male	18,02	0	yes
23	18	male	18,02	4	no
24	18	male	18,02	0	no
25	18	female	18,02	1	yes
26	18	female	18,02	4	yes
27	18	female	18,02	5	yes
28	18	female	18,02	5	yes
29	18	female	18,02	1	no
30	18	female	18,02	0	yes
31	18	male	18,02	5	yes
32	18	female	18,02	5	yes
33	18	male	18,02	1	yes
34	18	male	18,02	0	yes
35	18	male	18,02	4	no
36	18	male	18,02	0	no
37	18	female	18,02	1	yes

Aktywuj system Windows
Przejdź do ustawień, aby aktywować system Windows.

Close

6. Kostka OLAP

6.1 Wstęp: Przygotowanie środowiska pracy

Przed przystąpieniem do właściwej realizacji projektu, konieczne było odpowiednie przygotowanie i skonfigurowanie środowiska programistycznego. Narzędziem wykorzystywanym do budowy rozwiązania jest środowisko Microsoft Visual Studio 2017, jednak w swojej domyślnej konfiguracji nie posiadało ono wbudowanych szablonów niezbędnych do tworzenia wielowymiarowych kostek OLAP.

Aby umożliwić utworzenie projektu, należało doinstalować brakujące pakiety oraz rozszerzenia w następujących krokach:

1. Konfiguracja Instalatora Visual Studio: Za pomocą narzędzia Visual Studio Installer zmodyfikowano bieżącą instalację programu, upewniając się, że w sekcji „Magazynowanie i przetwarzanie danych” aktywowany jest pakiet SQL Server Data Tools (SSDT).
2. Instalacja rozszerzenia Analysis Services: Następnie konieczne było pobranie i zintegrowanie ze środowiskiem dedykowanego rozszerzenia o nazwie Microsoft Analysis Services Projects.

Po pomyślnej instalacji powyższych komponentów i ponownym uruchomieniu środowiska, w oknie tworzenia nowego rozwiązania pojawiła się kategoria Business Intelligence. Dzięki temu możliwe było wybranie docelowego szablonu projektu, czyli Analysis Services Multidimensional and Data Mining Project, i przejście do właściwego etapu projektowania kostki analitycznej.

Connection Manager

Provider: Native OLE DB\SQL Server Native Client 11.0

Connection

Server name: DESKTOP-IFD8LT5\WAD Refresh

Log on to the server

Authentication: Windows Authentication

User name: Password: Save my password

Connect to a database

☒ Select or enter a database name: Projekt



☐ Attach a database file: Browse... Logical name:


Test Connection OK Cancel Help

Connection Manager

Test connection succeeded.

Copy message OK





Podczas etapu wdrażania (Deployment) przygotowanej kostki OLAP do środowiska serwerowego napotkano błąd autoryzacji i połączenia z serwerem docelowym (localhost). Analiza komunikatów błędów w środowisku Visual Studio wykazała, że lokalna instancja bazy danych nie była w stanie przetworzyć struktury wielowymiarowej. Przyczyną problemu był brak zainstalowanego dedykowanego silnika analitycznego w początkowej konfiguracji serwera bazy danych (zainstalowany był jedynie podstawowy silnik relacyjny – Database Engine). W celu rozwiązania tego problemu i umożliwienia wdrożenia projektu, niezbędne było wykonanie następujących kroków:

1. Uruchomienie instalatora SQL Server 2025 Developer Edition.
2. Rozszerzenie istniejącej instancji poprzez instalację dodatkowego komponentu SQL Server Analysis Services (SSAS).
3. Skonfigurowanie nowej usługi SSAS w trybie Multidimensional and Data Mining Mode (Tryb wielowymiarowy i eksploracji danych), który jest wymagany do obsługi projektowanych kostek i modeli eksploracji danych.
4. Nadanie uprawnień administratora bieżącemu użytkownikowi w ramach usługi SSAS.

Po pomyślnej instalacji i uruchomieniu usługi SSAS, proces wdrażania (Deploy) oraz przetwarzania danych (Process) w Visual Studio zakończył się sukcesem, co pozwoliło na przejście do właściwego etapu analizy danych w przeglądarce kostki (Cube Browser).

Complete

Your SQL Server 2025 installation completed successfully with product updates.

Edition

License Terms

Global Rules

Microsoft Update

Product Updates

Install Setup Files

Install Rules

Feature Selection

Feature Rules

Instance Configuration

Server Configuration

Analysis Services Configuration

Feature Configuration Rules

Ready to Install

Installation Progress

Complete

Information about the Setup operation or possible next steps:

Feature	Status
✓ Analysis Services	Succeeded
✓ SQL Browser	Succeeded
✓ Setup Support Files	Succeeded


Details:

Install successful.

Summary log file has been saved to the following location:

C:\Program Files\Microsoft SQL Server\170\Setup Bootstrap\Log\20260424_123109\Summary_DESKTOP-IFD8LT5_20260424_123109.txt


Close



Zarządzanie uprawnieniami i rozwiązywanie konfliktów autoryzacji

W końcowej fazie wdrażania i przetwarzania (Processing) struktury OLAP napotkano błąd autoryzacji typu OLE DB ("Login failed"). Wynikał on z faktu, iż nowo utworzona usługa silnika analitycznego (SSAS) korzystała z wyizolowanego konta systemowego (w tym przypadku NT Service\MSOLAP\$KOSTKA), które domyślnie nie miało praw dostępu do źródłowej, relacyjnej bazy danych z tabelami faktów i wymiarów.

W celu zażegnania problemu, wykorzystano środowisko SQL Server Management Studio (SSMS). Skonfigurowano nowe logowanie (Login) na poziomie serwera bazy danych dla konta usługi SSAS, a następnie w zakładce User Mapping zmapowano je z docelową bazą projektową, nadając mu rolę db_datareader. Zabieg ten zapewnił kostce bezpieczny dostęp "tylko do odczytu" do danych źródłowych, co pozwoliło na bezbłędne przetworzenie (Process) wszystkich miar i wymiarów, i finalne wdrożenie rozwiązania.



6.2 Definiowanie warstwy analitycznej, miar podstawowych oraz agregacji MDX

Po pomyślnym zaimplementowaniu struktury relacyjnej i powiązaniu tabel wymiarów z centralną tabelą faktów, kluczowym etapem w ramach środowiska **SQL Server Analysis Services (SSAS)** było zaprojektowanie warstwy miar. Miary stanowią numeryczne jądro kostki wielowymiarowej i są obiektem bezpośrednich agregacji oraz analiz wykonywanych przez użytkowników biznesowych. W procesie konfiguracji grupy miar (*Measure Group*) dla



tabeli Fact_Insurance, system automatycznie wygenerował miary podstawowe, w tym Charges (sumaryczna kwota operacyjna) oraz Fact Insurance Count, pełniący funkcję licznika wierszy, czyli wolumenu aktywnych polis ubezpieczeniowych.

Samo operowanie na sumach globalnych jest jednak niewystarczające z punktu widzenia strategicznego zarządzania ryzykiem. Aby dostarczyć kadrze menedżerskiej zaawansowanych wskaźników efektywności, standardowy zestaw struktur rozbudowano o **miary obliczane (Calculated Measures)**. Zostały one zaimplementowane w zakładce *Calculations* przy użyciu restrykcyjnych wyrażeń w języku **MDX (Multi-Dimensional Expressions)**, co zapewnia ich dynamiczne i błyskawiczne przeliczanie w locie, niezależnie od stopnia agregacji czy nałożonych filtrów:

1. Średni koszt leczenia pacjenta ([Avg Charges]):

Jest to najważniejsza miara finansowa w systemie, wyliczana jako iloraz sumy opłat oraz całkowitej liczby pacjentów. Została ona zaimplementowana za pomocą następującego skryptu MDX:

$[Measures].[Avg\ Charges] = [Measures].[Charges] / [Measures].[Fact\ Insurance\ Count]$




W panelu właściwości miary nadano jej formatowanie Currency (Waluta), co zapewnia automatyczną prezentację danych w Power BI z symbolem walutowym i odpowiednią precyzją po przecinku. Miara ta pozwala aktuariuszom na natychmiastowe monitorowanie rzeczywistego obciążenia finansowego firmy w przeliczeniu na pojedynczego ubezpieczonego.

2. Średni wskaźnik masy ciała populacji ([Avg BMI]):

W celu monitorowania ryzyka fizjologicznego zaimplementowano miarę obliczaną wyznaczającą średnie BMI dla dowolnej podgrupy ubezpieczonych. Logika biznesowa opiera się na formule:

$$[Measures].[Avg BMI] = [Measures].[Sum BMI] / [Measures].[Fact Insurance Count]$$




Dla tej struktury zdefiniowano formatowanie **Standard (Liczbowy)**. Miara ta służy jako wczesne ostrzeżenie epidemiologiczne – pozwala na bieżąco kontrolować, czy w danym regionie geograficznym lub grupie zawodowej nie dochodzi do niebezpiecznego wzrostu wskaźnika otyłości.

3. Średni wiek portfela ubezpieczonych ([Avg Age]):

Struktura demograficzna ma kluczowe znaczenie dla stabilności funduszu odszkodowań, ponieważ koszty opieki medycznej rosną wraz z wiekiem. Średni wiek wyliczany jest za pomocą poniższego wyrażenia MDX:

$$[Measures].[Avg Age] = [Measures].[Sum Age] / [Measures].[Fact Insurance Count]$$



Miara ta otrzymała formatowanie **Standard**, umożliwiając natychmiastową kontrolę procesu starzenia się bazy klientów w dowolnym przekroju analitycznym.

<All>			
Projekt			
Measures			
Dim Patient			
Sum Age			
Sum BMI			
Fact Insurance			
Charges			
Fact Insurance Count			
Maximum Charges			
Minimum Charges			
Avg Age			
Avg BMI			
Avg Charges			
KPIs			
Dim Coverage			
Dim Medical			
Dim Patient			
Age			
Gender			
Patient Key			
Smoker			
Dim Profile			

Smoker	Gender	Avg Charges
no	female	13729,2709...
no	male	14738,9079...
yes	female	18736,9617...
yes	male	19732,3202...

Wdrożenie powyższych miar analitycznych pozwoliło na całkowite uniezależnienie warstwy prezentacji (Power BI) od konieczności przeprowadzania lokalnych obliczeń. Ponieważ silnik wielowymiarowy SSAS prekompiluje i optymalizuje te wartości na poziomie serwera, użytkownik końcowy, wybierając dowolny wymiar (np. filtrując dane po palących mężczyznach z regionu *Southeast*), otrzymuje poprawne, zaktualizowane wartości średnich kosztów leczenia, średniego wieku oraz wskaźnika BMI w czasie liczonym w milisekundach.


Stanowi to fundament pod budowę interaktywnych dashboardów oraz zaawansowanych systemów wspomagania decyzji menedżerskich (DSS).

6.3 Hierarchie wymiarów

W celu umożliwienia zaawansowanej analizy wielowymiarowej oraz zapewnienia intuicyjnego przeglądania danych, w projekcie zdefiniowano hierarchie w wymiarach. Kluczową hierarchią stworzoną na potrzeby analizy pacjentów jest hierarchia „Pacjenci_Logika” w wymiarze **Dim Patient**.

Struktura hierarchii „Pacjenci_Logika”:

1. **Gender (Płeć)** – najwyższy poziom agregacji, pozwalający na porównanie kosztów między kobietami a mężczyznami.
2. **Smoker (Status palacza)** – poziom umożliwiający analizę wpływu palenia tytoniu na wysokość składek wewnątrz grup płciowych.
3. **Age (Wiek)** – pozwala na uszczegółowienie analizy o konkretne roczniki pacjentów.
4. **Patient Key (Klucz pacjenta)** – najniższy poziom (liść), reprezentujący dane konkretnej osoby.




<All>					
Projekt Measures Dim Patient Fact Insurance Avg Age Avg BMI Avg Charges KPIs Dim Coverage Dim Medical Dim Patient Age Gender Patient Key Smoker Pacjenci_Logika Dim Profile					
Gender	Smoker	Age	Patient Key	Avg Charges	
female	no	18	3	13738,5223...	
female	no	18	6	13107,5210...	
female	no	18	8	13503,8282...	
female	no	18	17	12962,2604...	
female	no	18	52	13496,3027...	
female	no	18	66	12806,9675...	
female	no	19	41988	13155,6843...	
female	no	19	41990	13452,2824...	
female	no	19	42005	13548,2058...	
female	no	19	42006	13106,3602...	
female	no	19	42105	12800,0351...	
female	no	19	42122	13591,5152...	
female	no	20	83788	13051,8213...	
female	no	20	83789	13546,6236...	
female	no	20	83792	13793,3553...	
female	no	20	83793	13356,5685...	
female	no	20	83810	13093,1265...	
female	no	20	83811	12774,1832...	
female	no	21	125492	13474,8148...	
female	no	21	125501	13410,7597...	
female	no	21	125511	13187,0191...	
female	no	21	125524	13783,2881...	
female	no	21	125528	12733,3840...	
female	no	21	125595	12907,3160...	
female	no	22	170320	13719,5004...	
female	no	22	170322	13923,5424...	
female	no	22	170348	12698,2393...	

Zastosowanie analityczne: Zastosowanie powyższej hierarchii umożliwia użytkownikowi końcowemu (np. w narzędziu Power BI lub Excel) wykonywanie operacji typu **drill-down** (drążenie danych). Pozwala to na płynne przechodzenie od ogólnych trendów (np. średnie koszty dla wszystkich kobiet) do bardzo szczegółowych wniosków (np. średnie koszty dla palących mężczyzn w wieku 45 lat). Taka struktura znacząco skraca czas dotarcia do przyczyn wysokich kosztów medycznych w określonych grupach ryzyka.

Drugą istotną strukturą zdefiniowaną w modelu analitycznym jest hierarchia „**Profil_Zawodowy**” utworzona w wymiarze **Dim Profile**.

Struktura hierarchii:

1. **Region (Lokalizacja)** – najwyższy poziom, dzielący pacjentów ze względu na obszar geograficzny. Pozwala to na identyfikację regionów o najwyższym współczynniku zachorowalności lub najwyższych kosztach usług medycznych.
2. **Occupation (Zawód)** – drugi poziom, umożliwiający sprawdzenie, jak konkretne grupy zawodowe w obrębie danego regionu wpływają na obciążenie finansowe ubezpieczyciela.



Region	Occupation	Avg Charges
north...	Blue collar	17755,6873...
north...	Student	16737,5662...
north...	Unemployed	16225,8773...
north...	White collar	18227,9089...
north...	Blue collar	17023,8299...
north...	Student	16043,4925...
north...	Unemployed	15532,4765...
north...	White collar	17514,8778...
south...	Blue collar	17236,9390...
south...	Student	16243,0966...
south...	Unemployed	15753,6798...
south...	White collar	17734,3014...
south...	Blue collar	16914,5377...
south...	Student	15923,8802...
south...	Unemployed	15452,3030...
south...	White collar	17462,2540...

Zastosowanie analityczne: Hierarchia ta pozwala na wykrycie korelacji między miejscem zamieszkania a rodzajem wykonywanej pracy. Dzięki funkcjonalności **drill-down**, analityk może sprawdzić, czy wysokie średnie koszty leczenia w danym regionie (np. Southeast) wynikają z ogólnych trendów lokalnych, czy może są generowane przez konkretną grupę zawodową, która w tym regionie jest najbardziej liczna. Jest to kluczowe przy projektowaniu dedykowanych ofert ubezpieczeniowych dla firm z konkretnych branż w danych regionach.

6.4 Scenariusze KPI (Kluczowe Wskaźniki Efektywności)

Wskaźniki KPI (Key Performance Indicators) w środowisku OLAP nie służą jedynie do wyświetlania kolorowych obrazków, ale stanowią fundament systemów wspomagania decyzji (DSS – Decision Support Systems). Dla ubezpieczalni medycznej są one systemem wczesnego ostrzegania. Zamiast ręcznie przeglądać tysiące rekordów, kadra zarządzająca otrzymuje natychmiastową, wizualną informację o tym, czy firma realizuje swoje cele strategiczne, czy też zbliża się do kryzysu finansowego.

Aby zademonstrować te możliwości, w ramach projektu zdefiniowano cztery użyteczne biznesowo scenariusze. Konfigurację logiki oceny każdego z nich oparto na instrukcjach warunkowych w języku MDX.

Poniżej przedstawiono szczegółowy opis biznesowy i analityczny każdego ze zdefiniowanych scenariuszy:

6.4.1 Scenariusz 1: Kontrola rentowności polis (KPI_Sredni_Koszt)

- **Na czym polega:** Wskaźnik ten na bieżąco porównuje rzeczywisty średni koszt leczenia pacjentów (Avg Charges) z bezpiecznym progiem budżetowym, ustalonym przez dział finansowy na kwotę 15 000.
- **Do czego służy:** Głównym celem jest ochrona płynności finansowej ubezpieczalni. Wskaźnik (typu prędkościomierz) weryfikuje, czy firma nie dopłaca do interesu.
- **Jak można to wykorzystać w praktyce:** Jeśli dla konkretnej grupy klientów (np. palaczy z regionu południowego) wskaźnik zapala się na czerwono, jest to dla analityków twardy dowód, że obecne składki ubezpieczeniowe dla tej grupy są zbyt niskie. Pozwala to na szybką reakcję i renegocjację cennika polis, zanim firma poniesie straty.

The screenshot displays the 'KPI Organizer' application. On the left, a tree view shows the hierarchy of KPIs, with 'KPI_Sredni_Koszt' selected. Below this is a 'Calculation Tools' section with tabs for 'Metadata', 'Functions', and 'Templates'. The main area on the right is the configuration panel for the selected KPI. It includes fields for 'Name' (KPI_Sredni_Koszt), 'Associated measure group' (Fact Insurance), 'Value Expression' ([Measures].[Avg Charges]), 'Goal Expression' (15000), 'Status' (Gauge), and 'Trend' (Standard arrow). A 'Status expression' field contains a CASE statement in MDX. The bottom section is labeled 'Additional Properties'.

KPI Organizer

KPI

Name: KPI_Sredni_Koszt

Associated measure group: Fact Insurance

Value Expression: [Measures].[Avg Charges]

Goal Expression: 15000

Status: Gauge

Status expression:

```

CASE
WHEN KpiValue("KPI_Sredni_Koszt") < KpiGoal("KPI_Sredni_Koszt") THEN 1
WHEN KpiValue("KPI_Sredni_Koszt") > KpiGoal("KPI_Sredni_Koszt") THEN -1
ELSE 0
END

```

Trend: Standard arrow

Additional Properties

6.4.2 Scenariusz 2: Prewencja i ocena ryzyka (KPI_Srednie_BMI)

- **Na czym polega:** Scenariusz ten monitoruje średni wskaźnik masy ciała pacjentów (Avg BMI), sprawdzając, czy populacja mieści się w granicach normy (wartość docelowa: 26).
- **Do czego służy:** Jest to narzędzie do oceny ukrytego ryzyka medycznego. Nadwaga i otyłość są bezpośrednią przyczyną wielu kosztownych chorób przewlekłych (np. cukrzycy, chorób serca).
- **Jak można to wykorzystać w praktyce:** Ubezpieczalnia nie musi czekać, aż pacjenci zaczną chorować. Jeśli KPI dla jakiegoś segmentu klientów sygnalizuje przekroczenie normy BMI, firma może proaktywnie zaoferować im darmowe programy dietetyczne lub zniżki na karnety na siłownię. Taka prewencja w dłuższej perspektywie jest dla ubezpieczalni znacznie tańsza niż późniejsze leczenie powikłań.

The screenshot displays the 'KPI Organizer' application. On the left, a tree view shows a hierarchy of KPIs: 'KPI_Sredni_Koszt', 'KPI_Srednie_BMI' (selected), 'KPI_Liczba_Pacjentow', and 'KPI_Sredni_Wiek'. Below this, the 'Calculation Tools' section includes 'Metadata', 'Functions', and 'Templates' tabs, a 'Search Model' field, and a 'Measure Group' dropdown set to '<All>'. A list of dimensions is shown: 'Projekt', 'Measures', 'Dim Coverage', 'Dim Medical', 'Dim Patient', and 'Dim Profile'. The main configuration area on the right is for 'KPI_Srednie_BMI'. It includes fields for 'Name' (KPI_Srednie_BMI), 'Associated measure group' (Fact Insurance), 'Value Expression' ([Measures].[Avg BMI]), 'Goal Expression' (26), 'Status' (Gauge), and 'Status expression' (a CASE statement). The 'Trend' section is also visible with a 'Trend indicator' set to 'Standard arrow'.

6.4.3 Scenariusz 3: Ocena wolumenu sprzedaży (KPI_Liczba_Pacjentow)

- **Na czym polega:** Wskaźnik zlicza aktywne polisy (Fact Insurance Count) i sprawdza, czy firma osiągnęła zakładany cel sprzedażowy na poziomie minimum 1300 klientów.
- **Do czego służy:** Weryfikacja udziału w rynku. Nawet jeśli koszty leczenia są niskie, firma musi posiadać odpowiednio dużą bazę klientów, aby opłacić koszty stałe swojej działalności (np. pensje pracowników, systemy IT).
- **Jak można to wykorzystać w praktyce:** Przydatne dla dyrektorów sprzedaży. Wykorzystując hierarchię geograficzną (drill-down), mogą oni sprawdzić wskaźnik na poziomie regionów. Tam, gdzie "termometr" wskazuje niedobór klientów (wartość -1), należy uruchomić nowe kampanie marketingowe, aby zwiększyć sprzedaż.

6.4.4 Scenariusz 4: Stabilność demograficzna portfela (KPI_Sredni_Wiek)

- **Na czym polega:** Wskaźnik weryfikuje, czy średni wiek ubezpieczonych (Avg Age) utrzymuje się na bezpiecznym, stosunkowo młodym poziomie (cel poniżej 40 lat).
- **Do czego służy:** Zabezpieczenie przyszłości firmy. Koszty opieki medycznej rosną logarytmicznie wraz z wiekiem pacjentów. Starzejący się portfel klientów to gwarancja problemów finansowych w nadchodzących latach.
- **Jak można to wykorzystać w praktyce:** Jeśli sygnalizator zmieni kolor na czerwony, oznacza to, że ubezpieczalnia musi pilnie "odmłodzić" swoją bazę. Analitycy mogą na tej podstawie zarekomendować stworzenie agresywnych, tanich pakietów ubezpieczeniowych dedykowanych specjalnie dla studentów i młodych rodzin, aby zrównoważyć pulę ryzyka.

Analityka interaktywna (Praca z filtrami)

Prawdziwa siła kostki OLAP ujawnia się podczas interaktywnego drążenia danych. Użytkownik biznesowy może dynamicznie nakładać filtry, a system w ułamku sekundy przeliczy wszystkie cztery scenariusze od nowa. Zestawienie poniżej obrazuje sytuację, w której analityk sprawdził wyłącznie grupę pacjentów palących. Natychmiastowe załamanie wskaźników (zwłaszcza przekroczenie budżetu kosztowego) udowadnia, jak ogromnym czynnikiem ryzyka finansowego jest dla ubezpieczalni nałóg nikotynowy.

Dimension	Hierarchy	Operator	Filter Expression			
<Select dimension>						
Display Structure		Value	Goal	Status	Trend	Weight
 KPI_Liczba_Pacjentow		1000000	1300			
 KPI_Sredni_Koszt		\$16,735.12	15000			
 KPI_Sredni_Wiek		82.99	40			
 KPI_Srednie_BMI		68.00	26			

Dimension	Hierarchy	Operator	Filter Expression			
Dim Patient	 Smoker	Equal	{ yes }			
<Select dimension>						
Display Structure		Value	Goal	Status	Trend	Weight
 KPI_Liczba_Pacjentow		500129	1300			
 KPI_Sredni_Koszt		\$19,234.76	15000			
 KPI_Sredni_Wiek		83.01	40			
 KPI_Srednie_BMI		68.00	26			

7. Data mining

Create the Data Mining Structure

Specify if mining model should be created and select the most applicable technique.



- ☒ Create mining structure with a mining model

Which data mining technique do you want to use?

Microsoft Decision Trees

- ☐ Create mining structure with no models

Description:

The Microsoft Decision Trees algorithm is a classification algorithm that works well for predictive modeling. The algorithm supports the prediction of both discrete and continuous attributes.

< Back

Next >

Finish >>

Cancel

Specify the Training Data

Specify the columns used in your analysis.



Mining model structure:

☒	Tables/Columns	Key	☒ Input	☒ Predict...
☒	BMI	☐	☒	☐
☒	Charges	☐	☐	☒
☒	FactKey	☒	☐	☐
☒	Gender	☐	☒	☐
☒	Occupation	☐	☒	☐
☒	Region	☐	☒	☐
☒	Smoker	☐	☒	☐

Recommend inputs for currently selected predictable:

Suggest

< Back

Next >

Finish >>

Cancel

 New Mining Model ✕

Model name:

Algorithm name:

 New Mining Model ✕

Model name:

Algorithm name:

Structure	Decision_Trees	Clustering	Neural_Network	Linear_Regression
	Microsoft_Decision_Trees	Microsoft_Clustering	Microsoft_Neural_Network	Microsoft_Linear_Regression
Age	Input	Input	Input	Input
BMI	Input	Input	Input	Input
Charges	PredictOnly	PredictOnly	PredictOnly	PredictOnly
Fact Key	Key	Key	Key	Key
Gender	Input	Input	Input	Ignore
Occupation	Input	Input	Input	Ignore
Region	Input	Input	Input	Ignore
Smoker	Input	Input	Input	Ignore


7.1 Modelowanie Algorytmem Drzew Decyzyjnych (Microsoft Decision Trees)

Pierwszym modelem wdrożonym w ramach warstwy Data Mining był algorytm drzew decyzyjnych (Microsoft Decision Trees). Celem modelu była predykcja wysokości kosztów leczenia (Charges) na podstawie zestawu zmiennych demograficzno-zdrowotnych pacjenta.

Wizualna eksploracja wygenerowanego modelu w zakładce *Mining Model Viewer* pozwoliła na odtworzenie logicznej ścieżki decyzyjnej algorytmu. W węźle głównym (korzeniu drzewa) algorytm dokonał pierwszego, krytycznego podziału badanej populacji (wynoszącej 700 000 rekordów uczących) w oparciu o atrybut *Smoker*. Wskazuje to matematycznie, że nałóg tytoniowy generuje najwyższy zysk informacyjny i stanowi główny czynnik różnicujący obciążenia finansowe. W kolejnym kroku, wewnątrz wyodrębnionych gałęzi palaczy i niepalących, system zróżnicował pacjentów na podstawie atrybutu *Occupation* (zawód), tworząc niezależne liście dla studentów, bezrobotnych oraz pracowników fizycznych i biurowych.

Proces predykcji i utrwalania wyników: Aby zastosować wyuczony model w praktyce, w zakładce *Mining Model Prediction* przygotowano zapytanie prognozujące (DMX). Zmapowano wejściową tabelę danych badawczych (*Dane_Do_Miningu*) ze strukturą modelu, wybierając jako zmienną wyjściową prognozowane koszty (*Charges*) w powiązaniu z kluczem pacjenta (*FactKey*) i jego wiekiem (*Age*).

Wygenerowane w ten sposób prognozy (np. przewidywany koszt rzędu 13 630 zł dla pacjentów w wieku 20 lat w jednym z liści decyzyjnych) zostały masowo przeliczone, a cały wynik – obejmujący **45 432 wierszy** zbadanych przypadków – został zapisany bezpośrednio do tabeli docelowej w bazie danych pod nazwą *decision_tree_prediction*. Umożliwiło to późniejsze zintegrowanie tych prognoz z centralną hurtownią danych.



Save Data Mining Query Result

Data Source: Projekt New

Table Name: decision_tree_prediction ☐ Overwrite if exists

Add to DSV: Projekt

45432 rows processed

Stop Save Close

Mining Structure
Mining Models
Mining Model Viewer
Mining Accuracy Chart
Mining Model Prediction

Mining Model

- Decision_Trees
 - Age
 - BMI
 - Charges
 - FactKey
 - Gender
 - Occupation
 - Region
 - Smoker

Select Model...

Select Input Table(s)

- Dane_Do_Miningu
 - Age
 - BMI
 - Charges
 - FactKey
 - Gender
 - Occupation
 - Region
 - Smoker

Remove Table... Select Case Table... Modify Join...

Source	Field	Alias	Show	Group	And/Or	Criteria/Argument
Decision_Trees	Charges		☒			
Dane_Do_Miningu	FactKey		☒			
Dane_Do_Miningu	Age		☒			
			☐			

Mining Structure Mining Models Mining Model Viewer Mining Accuracy Chart Mining Model Prediction		
Charges	FactKey	Age
12116,526139...	532578	20
12116,526139...	533849	20
12116,526139...	535454	20
13630,799353...	81235	20
13630,799353...	123191	20
13630,799353...	116363	20
13630,799353...	28080	20
13630,799353...	28373	20
13630,799353...	224480	20
13630,799353...	204367	20
13630,799353...	179406	20
13630,799353...	180923	20
13630,799353...	148688	20
13630,799353...	146076	20
13630,799353...	117588	20
13630,799353...	621856	20
13630,799353...	649812	20
13630,799353...	612283	20
13630,799353...	606705	20
13630,799353...	519020	20
13630,799353...	551021	20
13630,799353...	540445	20
13630,799353...	477967	20
13630,799353...	399349	20
13630,799353...	428110	20
13630,799353...	386656	20
13630,799353...	421410	20
13630,799353...	356123	20
13630,799353...	334602	20
13630,799353...	330062	20
13630,799353...	269566	20
13630,799353...	263478	20
13630,799353...	296536	20
14113,412614...	314100	20
14113,412614...	307651	20

7.2 Grupowanie Pacjentów – Analiza Skupień (Microsoft Clustering)


Drugim modelem eksploracji danych, zaimplementowanym w celu dywersyfikacji predykcji, był algorytm analizy skupień (Microsoft Clustering). W przeciwieństwie do nadzorowanych drzew decyzyjnych, technika ta działa w trybie nienadzorowanym. Jej głównym zadaniem jest automatyczna, wielowymiarowa segmentacja pacjentów na naturalne, homogeniczne grupy (kohorty) o zbliżonych profilach ryzyka i wynikających z nich kosztach.

Wizualna analiza wygenerowanego diagramu w zakładce *Mining Model Viewer* (widok *Cluster Diagram*) ukazuje podział populacji ubezpieczonych na 10 odrębnych klastrów. Zastosowanie zmiennej cieniującej opartej na liczebności (*Shading Variable: Population*) pozwala na szybką identyfikację dominujących profili – najciemniejsze węzły (m.in. Cluster 1, 2 i 3) reprezentują najbardziej typowe i najliczniejsze grupy pacjentów w portfolio. Gęsta

sieć krawędzi łączących klastry (widoczna w prawej części diagramu) wskazuje na silne podobieństwo cech między segmentami standardowymi, podczas gdy wyizolowane węzły peryferyjne (np. Cluster 1, Cluster 4) reprezentują specyficzne, rzadsze zjawiska medyczno-demograficzne.

Proces predykcji i utrwalania wyników: Aby zoperacjonalizować wyuczony model, w zakładce *Mining Model Prediction* skonfigurowano proces masowego prognozowania (DMX). Zestawiono model klastrowania ze zbiorem danych wejściowych (Dane_Do_Miningu), mapując atrybuty takie jak klucz faktu (FactKey) oraz wiek (Age), aby dla każdego przypisanego do danego klastra pacjenta wygenerować przewidywaną wartość kosztów leczenia (Charges).

Otrzymane prognozy, opierające się na uśrednionym profilu danego skupiska (np. stabilna wartość 16 365 zł dla 18-latków w jednym z klastrów), zostały masowo wygenerowane dla zbioru obejmującego **50 921 wierszy**. Wynik działania algorytmu został wyeksportowany i zapisany bezpośrednio w relacyjnej bazie danych jako docelowa tabela clusters_prediction. Stanowi to niezbędny krok do późniejszej integracji wyników w kostce OLAP i ich zestawienia z kosztami rzeczywistymi.



Save Data Mining Query Result

Data Source: Projekt New

Table Name: clusters_prediction ☐ Overwrite if exists

Add to DSV: Projekt

50921 rows processed

Stop Save Close

Mining Structure Mining Models Mining Model Viewer Mining Accuracy Chart Mining Model Prediction

Mining Model

- Clustering
 - Age
 - BMI
 - Charges
 - Fact Key
 - Gender
 - Occupation
 - Region
 - Smoker

Select Model...

Select Input Table(s)

- Dane_Do_Miningu
 - Age
 - BMI
 - Charges
 - FactKey
 - Gender
 - Occupation
 - Region
 - Smoker

Remove Table... Select Case Table... Modify Join...

Source	Field	Alias	Show	Group	And/Or	Criteria/Argument
Clustering	Charges		☒			
Dane_Do_Miningu	FactKey		☒			
Dane_Do_Miningu	Age		☒			
			☐			

Mining Structure Mining Models Mining Model Viewer Mining Accuracy Chart Mining Model Prediction

Charges	FactKey	Age
16365,032672...	375765	18
16365,032672...	413366	18
16365,032672...	290195	18
16365,126963...	68953	18
16365,126963...	15725	18
16365,126963...	16685	18
16365,126963...	17514	18
16365,126963...	19618	18
16365,126963...	9327	18
16365,126963...	58839	18
16365,126963...	447590	18
16365,126963...	386122	18
16365,126963...	387096	18
16365,126963...	431193	18
16365,126963...	362154	18
16365,126963...	353023	18
16365,126963...	315942	18
16365,126963...	252908	18
16365,126963...	200463	18
16365,126963...	189575	18
16365,126963...	185339	18
16365,126963...	127803	18
16365,126963...	119963	18
16365,126963...	123245	18
16365,126963...	43379	18
16365,126963...	88024	18
16365,126963...	36301	18
16365,322621...	325088	18
16365,322621...	325116	18
16365,322621...	329238	18
16365,322621...	330967	18
16365,322621...	323406	18
16365,322621...	323628	18
16365,322621...	294481	18
16365,322621...	242943	18

7.3 Analiza Wrażliwości i Predykcja Siecią Neuronową (Microsoft Neural Network)


Trzecim, najbardziej zaawansowanym matematycznie elementem wdrożonego ekosystemu sztucznej inteligencji była wielowarstwowa sieć neuronowa (Microsoft Neural Network). W przeciwieństwie do klasycznych modeli statystycznych, algorytm ten doskonale radzi sobie z mapowaniem skomplikowanych, nieliniowych i ukrytych zależności w gigantycznych zbiorach danych.

W celu zbadania siły wpływu poszczególnych zmiennych na obciążenie finansowe, wykorzystano widok analizy wrażliwości (*Sensitivity Analysis*) w przeglądarce modelu. Zmienna predykcyjna Charges została podzielona na dwa rozłączne przedziały: niższy (od 3 964 do 13 761 zł) oraz wyższy (od 13 761 do 16 740 zł). Graficzna analiza słupkowa dostarczyła kluczowych dowodów na temat struktury ryzyka:

- **Dominacja nałogu:** Najdłuższy słupek odchylony mocno w prawą stronę należy do atrybutu Smoker = yes, co czyni nałóg nikotynowy absolutnie najsilniejszym faktorem faworyzującym najwyższe koszty medyczne. Jednocześnie Smoker = no jako jedyny atrybut silnie faworyzuje spadek kosztów (odchylenie w lewo).
- **Korelacje wielowymiarowe:** Sieć zidentyfikowała, że kolejne pozycje podnoszące koszty to praca biurowa (Occupation = White collar), zamieszkanie na północnym wschodzie (Region = northeast) oraz płeć męska i starszy wiek.

Proces predykcji i utrwalania wyników: Aby przekuć model teoretyczny w działające rozwiązanie biznesowe, w zakładce *Mining Model Prediction* skonfigurowano zapytanie DMX (Data Mining Extensions). Struktura wyuczonej sieci neuronowej (Neural_Network) została zmapowana z tabelą danych wejściowych (Dane_Do_Miningu). Wybrano kolumnę prognozowaną Charges w kontekście atrybutów identyfikujących pacjenta (FactKey oraz Age).

Wygenerowane prognozy (wskazujące na przykład przewidywany koszt rzędu 14 338 zł dla części 18-latków zidentyfikowanych przez sieć jako grupa podwyższonego ryzyka) zostały przeliczone masowo. Wynik działania algorytmu, obejmujący dokładnie **51 600 przetworzonych wierszy**, został bezbłędnie wyeksportowany i utrwalony w relacyjnej bazie danych w dedykowanej tabeli neural_network_prediction. Zakończenie tego etapu zamknęło proces generowania predykcji AI, umożliwiając ich ostateczne podłączenie do centralnej tabeli faktów i wizualizację w programie Power BI.



Save Data Mining Query Result

Data Source:

Projekt

New

Table Name:

neural_network_prediction


☐ Overwrite if exists

Add to DSV:

Projekt

51600 rows processed

Stop Save Close



Charges	FactKey	Age
14338,402148...	375765	18
14338,402148...	413366	18
14338,402148...	285479	18
14633,221462...	15725	18
14633,221462...	16685	18
14633,221462...	17514	18
14633,221462...	19618	18
14633,221462...	68953	18
14633,221462...	9327	18
14633,221462...	58839	18
14633,221462...	447590	18
14633,221462...	386122	18
14633,221462...	387096	18
14633,221462...	431193	18
14633,221462...	362154	18
14633,221462...	353023	18
14633,221462...	315942	18
14633,221462...	252908	18
14633,221462...	200463	18
14633,221462...	185339	18
14633,221462...	189575	18
14633,221462...	127803	18
14633,221462...	119963	18
14633,221462...	123245	18
14633,221462...	43379	18
14633,221462...	36301	18
14633,221462...	88024	18
15289,720288...	325116	18
15289,720288...	329238	18
15289,720288...	330967	18
15289,720288...	284056	18
15289,720288...	323406	18
15289,720288...	323628	18
15289,720288...	294481	18
15289,720288...	242943	18

7.4 Integracja Wyników Predykcyjnych ze Strukturą Wielowymiarową Kostki OLAP

Ostatnim, krytycznym krokiem całego procesu Data Mining była integracja wygenerowanych tabel prognoz z centralnym środowiskiem analitycznym SQL Server Analysis Services (SSAS). Stanowi to technologiczny most pomiędzy wyuczonymi modelami sztucznej inteligencji a docelową warstwą raportową dla biznesu.

Proces ten przebiegał w dwóch zasadniczych etapach:


1. Rozbudowa Architektury Relacyjnej (Data Source View): Jak ukazuje zaktualizowany schemat widoku źródła danych, trzy tabele zawierające wyeksportowane wyniki algorytmów (decision_tree_prediction, clusters_prediction, neural_network_prediction) zostały zaimportowane do modelu. Aby powiązać predykcje z rzeczywistym wymiarem demograficzno-czasowym, każdą z tabel połączono bezpośrednio z centralną tabelą faktów (Fact_Insurance) relacją jeden-do-jednego za pomocą unikalnego identyfikatora FactKey. Taki zabieg rozszerzył klasyczny schemat gwiazdy, gwarantując pełną synchronizację prognoz AI z historycznymi profilami pacjentów.

2. Definiowanie Grup Miar i Agregacji MDX: Na podstawie dodanych tabel predykcyjnych utworzono w kostce trzy nowe grupy miar (*Measure Groups*). Środowisko SSAS domyślnie wygenerowało dla nich miary sumaryczne (np. Charges - Decision Tree Prediction) oraz liczniki wolumenowe (np. Decision Tree Prediction Count).

Operowanie na sumach absolutnych uniemożliwiłoby jednak rzetelne, biznesowe porównanie modeli predykcyjnych z rzeczywistym, średnim kosztem leczenia. Dlatego w zakładce *Calculations* wprowadzono zaawansowaną logikę z wykorzystaniem wyrażeń **MDX (Multi-Dimensional Expressions)**, tworząc trzy nowe miary obliczane (Calculated Measures):

- [avg_Drzewo] – weryfikująca model drzew decyzyjnych.
- [avg_cluster] – weryfikująca model analizy skupień.
- [avg_siec] – weryfikująca model sieci neuronowych.

Każda z tych miar została zaprogramowana jako iloraz zagregowanej sumy przewidywanych kosztów z danego modelu przez całkowitą liczbę przetworzonych w nim wierszy (np. [Measures].[Charges - Neural Network Prediction] / [Measures].[Neural Network Prediction Count]). Otrzymanym w ten sposób predykcjom średnich kosztów przypisano walutowy format wyświetlania, co ostatecznie udostępniło ustrukturyzowane i zwalidowane wyniki modeli sztucznej inteligencji bezpośrednio na zewnątrz, przygotowując je do wizualizacji i zestawień na pulpitych Power BI.



Measures	
Projekt	
Fact Insurance	
Dim Patient	
Decision Tree Prediction	
Charges - Decision Tree Prediction	
Age	
Decision Tree Prediction Count	
Clusters Prediction	
Charges - Clusters Prediction	
Age - Clusters Prediction	
Clusters Prediction Count	
Neural Network Prediction	
Charges - Neural Network Prediction	
Age - Neural Network Prediction	
Neural Network Prediction Count	

Script Organizer

Command

1 CALCULATE

2 [avg_Drzewo]

3 [Avg Charges]

4 [Avg Age]

5 [Avg BMI]

Calculation Tools

Metadata Functions Templates

Search Model

Measure Group: <All>

Project

Measures

Dim Coverage

Dim Medical

Dim Patient

Dim Profile

Name: [avg_Drzewo]

Parent Properties

Parent hierarchy: Measures

Parent member: Change

Expression

[Measures].[Charges - Decision Tree Prediction] / [Measures].[Decision Tree Prediction Count]

Additional Properties

Format string:

Visible: True

Non-empty behavior:

Associated measure group: Decision Tree Pr

Display folder:

Color Expressions

Font Expressions

Script Organizer

Command

1 CALCULATE

2 [avg_Drzewo]

3 [avg_cluster]

4 [Avg Charges]

5 [Avg Age]

6 [Avg BMI]

Calculation Tools

Metadata Functions Templates

Search Model

Measure Group:

Name: [avg_cluster]

Parent Properties

Parent hierarchy: Measures

Parent member: Change

Expression

[Measures].[Charges - Clusters Prediction] / [Measures].[Clusters Prediction Count]

Additional Properties

Format string:

Visible: True

Non-empty behavior:

Associated measure group: Clusters Predict

Display folder:

Color Expressions

Font Expressions

Script Organizer

Command

1 CALCULATE

2 [avg_Drzewo]

3 [avg_cluster]

4 [avg_siec]

5 [Avg Charges]

6 [Avg Age]

7 [Avg BMI]

Calculation Tools

Metadata Functions Templates

Search Model

Measure Group:

Name: [avg_siec]

Parent Properties

Parent hierarchy: Measures

Parent member: Change

Expression

[Measures].[Charges - Neural Network Prediction] / [Measures].[Neural Network Prediction Count]

Additional Properties

Format string:

Visible: True


Non-empty behavior:

Associated measure group: Neural Network

Display folder:

Color Expressions

Font Expressions



8. Wizualizacje w Power BI

Ostatecznym i kluczowym z punktu widzenia użytkownika biznesowego etapem wdrożenia systemu Business Intelligence było zaprojektowanie oraz zaimplementowanie interaktywnego środowiska raportowo-analitycznego w programie Power BI Desktop. Aby zapewnić najwyższą wydajność operacyjną oraz pełną spójność danych, raport został połączony bezpośrednio z wielowymiarową bazą analityczną SQL Server Analysis Services (SSAS) za pomocą dedykowanego mechanizmu połączenia na żywo (**Connect Live** do instancji serwera localhost\kostka, baza danych: Projekt).

Zastosowanie architektury *Connect Live* przenosi cały ciężar skomplikowanych obliczeń i agregacji bezpośrednio na wydajny serwerowy silnik analityczny SSAS. Każda interakcja użytkownika, zmiana zakresu filtrowania czy drążenie danych (*drill-down*) w programie Power BI powoduje natychmiastowe wygenerowanie i przesłanie w tle zapytania do kostki, która zwraca gotowe wyniki w czasie liczonego w milisekundach.

W ramach warstwy wizualizacyjnej wdrożono strukturę składającą się z trzech odrębnych, spójnych stylistycznie kart raportowych (ekranów), z których każdy realizuje dedykowany scenariusz analityczny dla kadry menedżerskiej przedsiębiorstwa ubezpieczeniowego.

Baza danych usług SQL Server Analysis Services



Serwer

localhost\kostka

Baza danych

OK

Anuluj

Windows

Podstawowy

Konto Microsoft

Uzyskiwanie dostępu do usług SQL Server Analysis Services

localhost\kostka

Użyj poświadczeń systemu Windows, aby uzyskać dostęp do usług Analysis Services.

☒ Użyj moich bieżących poświadczeń

☐ Użyj alternatywnych poświadczeń


Nazwa użytkownika

Hasło


Wstecz

Połącz

Anuluj



8.1 Raport 1: Walidacja Modeli Predykcyjnych Sztucznej Inteligencji i Trendy Wiek



Pierwsza strona raportu została zaprojektowana jako najbardziej zaawansowany panel naukowo-walidacyjny. Jej zadaniem jest bezpośrednie zestawienie historycznych kosztów rzeczywistych z prognozami wygenerowanymi przez trzy niezależne modele eksploracji danych (*Data Mining*) wyeksportowane z silnika serwerowego.

1. **Centralny Wykres Walidacji AI (Wykres Liniowy – *Line Chart*):** Głównym elementem tej strony jest zaawansowany wykres liniowy pt. "*Porównanie predykcji modeli Data Mining z kosztami rzeczywistymi*". Na osi X osadzono atrybut wieku Age, natomiast na osi Y umieszczono cztery konkurujące ze sobą linie miar:

- **Linia fioletowa (Avg Charges):** Reprezentuje faktyczne, historyczne koszty poniesione przez firmę.
- **Linia jasnoniebieska (avg_Drzewo):** Prognoza algorytmu Drzew Decyzyjnych (*Microsoft Decision Trees*).
- **Linia ciemnoniebieska (avg_cluster):** Prognoza algorytmu Analizy Skupień (*Microsoft Clustering*).
- **Linia pomarańczowa (avg_siec):** Prognoza algorytmu Sieci Neuronowej (*Microsoft Neural Network*).


Podczas implementacji wykresu rozwiązano dwa istotne problemy techniczne. Po pierwsze, za pomocą menu opcji zaawansowanych wizualizacji (trzy kropki ... → *Sortuj oś*), zmieniono domyślny algorytm sortowania Power BI, ustawiając oś X ściśle według atrybutu Age w ujęciu rosnącym (*Sort ascending*), co wyeliminowało chaotyczne zygzaki i ułożyło wiek chronologicznie od 18 do 41 roku życia. Po drugie, ze względu na specyfikę zbiorów treningowych w silniku Data Mining, linie predykcji kończyły się na 41 roku życia. Aby wykres był w pełni czytelny i profesjonalny, wykorzystano panel filtrowania podstawowego

(*Basic Filtering*) na poziomie elementu wizualnego, odznaczając roczniki od 42 wzwyż. Dzięki temu wykres idealnie wypełnił przestrzeń od krawędzi do krawędzi.

Wnioski z wykresu walidacyjnego: Koszty rzeczywiste (linia fioletowa) wykazują wyraźny trend wzrostowy wraz z wiekiem pacjenta. Modele *Sieci Neuronowej* (linia pomarańczowa) oraz *Drzew Decyzyjnych* (linia jasnoniebieska) wykazują najwyższą precyzję, dynamicznie podążając za lokalnymi wahaniami i idealnie odzwierciedlając trend rzeczywisty. Z kolei model klastrowania (linia ciemnoniebieska) wyznacza stabilną, uśrednioną linię stałą dla całej kohorty wiekowej, co udowadnia, że do produkcyjnego systemu automatycznej wyceny polis w systemie CRM należy wdrożyć algorytm sieci neuronowej lub drzew decyzyjnych jako najbardziej czułe na zmiany demograficzne.

2. **Składniki Kosztów według Stanowisk (Wykres Kaskadowy – *Waterfall Chart*):** U dołu ekranu zaimplementowano wykres kaskadowy obrazujący miarę Avg Charges w rozbiciu na grupy zawodowe Occupation. Słupki kaskady (schodki zielone) w sposób narastający wizualizują, jak poszczególne zawody (White collar, Blue collar, Student, Unemployed) dokładają swoje cegiełki finansowe, budując od zera ostateczny, sumaryczny słupek końcowy (Suma – kolor niebieski). Wykres ten doskonale prezentuje strukturę i wkład poszczególnych segmentów rynku w globalne wydatki firmy.
3. **Hierarchia Kosztów Jednostek Chorobowych (Wykres Lejkowy – *Funnel Chart*):** Obok kaskady umieszczono wykres lejkowy zestawiający Avg Charges z historią chorób Medical_History. Wykres automatycznie sortuje dane, tworząc biznesową piramidę wydatków – od najdroższych schorzeń serca na samej górze (najszerszy pasek lejka stanowiący 100% bazy odniesienia), przez cukrzycę i nadciśnienie, aż po osoby całkowicie zdrowe (*None*) na samym dole, u których leczenie jest najtańsze i stanowi 74,7% kosztów grupy najwyższego ryzyka.
4. **Nowoczesne Slicery Kafelkowe (Styl *Tiles*):** W prawym dolnym rogu przeprowadzono modernizację wizualną filtrów dla zmiennych Smoker oraz Gender. Za pomocą panelu formatowania (*Ustawienia fragmentatora* → *Styl*) zmieniono standardową listę wyboru na nowoczesne, różowo-niebieskie przyciski kafelkowe (*Tiles*). Nadaje to aplikacji nowoczesny, dotykowy wygląd, upraszczając nawigację menedżerską.

8.2 Raport 2: Analiza Struktury Finansowej i Wpływu Obciążeń Chorobowych




Druga karta raportu została zaprojektowana jako centralny pulpit operacyjny dla dyrekcji finansowej oraz lekarzy orzeczników. Jej głównym celem jest prezentacja globalnych wskaźników wolumenowych oraz identyfikacja bezpośredniego wpływu jednostek chorobowych na koszty medyczne.

- Warstwa Wskaźników Głównych (Ręcznie implementowane wskaźniki KPI):** Na samej górze ekranu wdrożono autorskie, dwuelementowe panele wskaźnikowe, zbudowane na bazie przezroczystych wizualizacji typu Karta (*Card*), które nałożono na dedykowane, geometryczne tła w celu uzyskania nowoczesnego wyglądu.
 - Karta "Całkowita liczba pacjentów":** Wyświetla zagregowaną miarę ilościową populacji objętej systemem ubezpieczeniowym, która osiągnęła status **1 mln** ubezpieczonych.
 - Karta "Średni koszt leczenia":** Prezentuje kluczową miarę obliczaną kostki, czyli średni koszt przypadający na jednego ubezpieczonego, o wartości **16,74 zł tys.**
- Rozkład Populacji w Ujęciu Geograficznym (Mapa Drzewa – *Treemap*):** W lewej sekcji ekranu umieszczono wykres blokowy mapy drzewa obrazujący strukturę terytorialną bazy klientów. Wizualizacja ta dzieli przestrzeń na proporcjonalne, kolorowe kafelki reprezentujące regiony (northeast, northwest, southeast, southwest). Rozmiar kafelka odpowiada wolumenowi miary Fact Insurance Count. Z wykresu bezpośrednio wynika, że największa koncentracja pacjentów występuje w regionie północno-wschodnim (*northeast*), co stanowi kluczową wytyczną dla departamentu marketingu.
- Analiza Współzależności Ryzyka Chorobowego i Nalogu (Wykres Słupkowy Grupowany):** Prawą stronę ekranu zajmuje zaawansowany poziomy wykres słupkowy

grupowany pt. "Wpływ historii chorób i palenia na koszty". Wizualizacja zestawia miarę Avg Charges (Oś X) z historią medyczną pacjenta Medical_History (Oś Y). Dodatkowo, słupki zostały rozbite za pomocą legendy determinującej status nałogu tytoniowego Smoker (kolor jasnoniebieski dla osób niepalących, kolor ciemnoniebieski dla palaczy). Wykres ten dostarcza natychmiastowych wniosków biznesowych: niezależnie od zdiagnozowanej choroby, pacjenci palący generują drastycznie wyższe koszty. Najwyższe obciążenie dla budżetu ubezpieczyciela stanowią osoby z historią chorób serca (*Heart disease*) oraz cukrzycą (*Diabetes*), u których skorelowany nałóg nikotynowy powoduje wystrzelenie średniego kosztu leczenia powyżej krytycznej granicy 20,00 zł tys.

4. **Panel Filtrowania Dynamicznego:** U dołu ekranu zaimplementowano rząd czterech spójnych fragmentatorów (*Slicers*) pozwalających na błyskawiczne zawężanie danych na całej stronie według kryteriów: Płeć (*Gender*), Osoba paląca (*Smoker*), Region oraz Zawód (*Occupation*).

8.3 Raport 3: Koncentracja Ryzyka Fizjologicznego i Analiza Geograficzno-Matrycowa



Trzecia karta raportu została podporządkowana zaawansowanej analityce korelacji cech fizjologicznych (wskaźnika BMI) oraz pozycji społeczno-zawodowej pacjentów w ujęciu terytorialnym.

1. **Krzyżowa Matryca Kosztów (Wizualizacja typu Macierz – *Matrix*):** W lewym górnym rogu umieszczono tabelę macierzową prezentującą miarę Avg Charges w ujęciu wielowymiarowym. W wierszach matrycy osadzono atrybut Region, natomiast w kolumnach zmienną zawodową Occupation (Blue collar, Student, Unemployed, White collar). Wizualizacja została wzbogacona o zaawansowane formatowanie warunkowe (kolorowanie tła jako mapa cieplna w odcieniach niebieskich). Pozwala to menedżerowi na natychmiastową identyfikację najdroższych kohort społecznych. Tabela jednoznacznie ujawnia, że najwyższy jednostkowy koszt leczenia (18 227,91 zł) generują pracownicy biurowi (*White collar*) w regionie północno-wschodnim (*northeast*).
2. **Wskaźnik Zegarowy Efektywności Budżetowej (Wykres Wskaźnikowy – *Gauge Chart*):** Poniżej macierzy zaimplementowano nowoczesny wykres prędkościomierza prezentujący miarę Avg Charges. W panelu formatowania manualnie zdefiniowano właściwość osi wskaźnika, ustawiając wartość maksymalną (*Maximum*) na stały próg 50,00 zł tys. Wykres ten pełni rolę dynamicznego budzika finansowego – pozwala na bieżąco monitorować, jak daleko aktualny, przefiltrowany profil pacjentów znajduje się od absolutnego limitu rentowności ubezpieczeń medycznych.
3. **Wykres Rozrzutu i Dwustrefowa Separacja Ryzyka (Wykres Punktowy – *Scatter Chart*):** Prawą, dominującą część ekranu zajmuje wykres punktowy pt. "*Zależność kosztów leczenia od BMI i nałogu tytoniowego*". Na osi X osadzono miarę Avg BMI, natomiast na osi Y miarę Avg Charges. Jako element rozbijający chmurę punktów (*Details*) wykorzystano wiek pacjentów Age, a legenda ponownie została powiązana ze zmienną Smoker. Wizualizacja ta stanowi jeden z najsilniejszych punktów całego projektu BI, generując spektakularną, dwuwarstwową separację danych. Na dole wykresu (w przedziale 12,00 - 14,00 zł tys.) układają się jasnoniebieskie punkty reprezentujące osoby niepalące, u których wzrost wskaźnika masy ciała (BMI) wykazuje jedynie łagodny, stabilny wpływ na koszty. Z kolei na samej górze wykresu (w okolicach 20,00 zł tys.) gromadzi się całkowicie oddzielona chmura ciemnoniebieskich punktów oznaczających palaczy. Wykres ten stanowi dla aktuariuszy bezdyskusyjny, matematyczny dowód na to, że współwystępowanie wysokiego BMI (otyłości powyżej progu 30) wraz z nałogiem nikotynowym wywołuje synergiczny, nieliniowy skok ryzyka finansowego, co bezwzględnie musi skutkować drastycznym podniesieniem składki bazowej.

8.4 Raport 4: Wielowymiarowa analiza struktury operacyjnej i profilu zachorowalności populacji



Ostatnia karta zaimplementowanego środowiska Power BI stanowi kompleksowy panel przekrojowy, dedykowany dla analityków operacyjnych oraz kadry zarządzającej departamentem ryzyka produktowego. Cel tego pulpitu to jednocześnie badanie korelacji cech socjodemograficznych (regionu oraz wykonywanej profesji) z obciążeniem klinicznym (historią chorób pacjentów) i mapowanie ich bezpośredniego przełożenia na miary ilościowe oraz finansowe ubezpieczyciela.

Na strukturę analityczną tego ekranu składają się następujące komponenty wizualne:

1. **Struktura Wolumenu i Trendu Średnich Kosztów według Wiek** (Wykres Mieszany – *Combo Chart*): Górną oś całego panelu zajmuje zaawansowany wykres kolumnowy i liniowy zatytułowany „*Fact Insurance Count i Avg Charges wg Age*”. Realizuje on kluczowe zadanie wdrożeniowe:
 - **Słupki jasnoniebieskie (Fact Insurance Count)**: Odzwierciedlają wolumen aktywnych polis ubezpieczeniowych. Rozkład kolumn potwierdza całkowicie stabilną i homogeniczną liczebność próbki w każdym z roczników populacji.
 - **Linia ciemnoniebieska (Avg Charges)**: Reprezentuje miarę obliczaną średniego kosztu leczenia. Oś X została posortowana rosnąco chronologicznie (od 18 do 65 lat), dzięki czemu wizualizacja w sposób niepodważalny obrazuje stały trend wzrostowy. Wraz z wiekiem ubezpieczonego, koszty medyczne progresywnie pną się w górę, ujawniając lokalne skoki szkodowości w przedziałach dojrzałych, co stanowi jasną wytyczną dla matematyków aktuarialnych wyceniających rezerwy finansowe.
2. **Geograficzno-Zawodowa Matryca Kumulacji Wydatków** (Wykres Skumulowany Kolumnowy): W lewej dolnej sekcji osadzono wykres „*Avg Charges wg Region i Occupation*”. Układ ten wykorzystuje zaawansowane dzielenie segmentowe: na osi X

reprezentowane są cztery regiony operacyjne (*northeast, southeast, northwest, southwest*), natomiast legenda rozбивa każdy słupek na skumulowane warstwy zawodowe (*Blue collar, Student, Unemployed, White collar*). Wykres ten udowadnia niezmienną strukturalną ryzyka – w każdym z analizowanych regionów to pracownicy biurowi (*White collar*) generują najwyższe jednostkowe koszty medyczne (osiągające poziom blisko 18,00 zł tys.), podczas gdy profile studenckie stale utrzymują się na najniższym poziomie alokacji budżetowej.

3. **Biznesowa Piramida Ciężaru Medycznego (Wykres Lejkowy – *Funnel Chart*):** Środkową część dolnego panelu zajmuje wykres „*Avg Charges wg Medical History*”. Prezentuje on rozkład kosztów w ujęciu czysto klinicznym, automatycznie hierarchizując jednostki chorobowe:
 - **Wierzchołek lejka (100% bazy odniesienia):** Stanowią choroby serca (*Heart disease*) ze średnią wartością roszczenia wynoszącą **19,74 zł tys.**
 - **Poziomy pośrednie:** Cukrzyca (*Diabetes* – 16,75 zł tys.) oraz nadciśnienie tętnicze (*High blood pressure* – 15,72 zł tys.).
 - **Podstawa lejka:** Osoby wykazujące brak historii chorób przewlekłych (*None*), u których jednostkowy koszt wynosi **14,74 zł tys.**, co stanowi dokładnie 74,7% wartości grupy kardiologicznej najwyższego ryzyka.
4. **Nowoczesny Blok Fragmentatorów Kafelkowych (Styl *Tiles*):** Po prawej stronie zaimplementowano interaktywne kontrolki filtrów dynamicznych dla wymiarów Smoker oraz Gender. Poprzez rezygnację ze standardowych list rozwijanych na rzecz przycisków typu *Tiles* (różowo-niebieskie kafelki), interfejs zyskał cechy nowoczesnej aplikacji zarządczej. Wybranie dowolnego kafli (np. Smoker = yes) natychmiastowo filtruje i przebudowuje wszystkie opisane wyżej wykresy na stronie, umożliwiając menedżerom realizację błyskawicznych symulacji finansowych i testów stresu dla portfela polis w czasie rzeczywistym.

9. Podsumowanie

Niniejszy projekt inżynierski stanowił kompleksowe, produkcyjne wdrożenie zaawansowanego systemu klasy Business Intelligence (BI) oraz Data Mining w sektorze ubezpieczeń zdrowotnych. Całość prac została oparta na potoku przetwarzania danych operacyjnych (*Data Pipeline*), obejmującym wolumen ponad jednego miliona rekordów. Wszystkie etapy projektu – począwszy od masowego importu i profilowania danych w warstwie przejściowej, przez automatyzację potoków ETL w SSIS, budowę wielwymiarowych struktur analitycznych i wskaźników efektywności w SSAS, aż po integrację modeli predykcyjnych sztucznej inteligencji oraz wdrożenie interaktywnej warstwy prezentacji w

Power BI – zostały pomyślnie zrealizowane, tworząc spójny i wysoce wydajny system wspomagania decyzji menedżerskich (DSS).

Wnioski z Realizacji Poszczególnych Etapów Inżynierii Danych

Warstwa Integracji i Jakości Danych (SSIS): Proces zasilania hurtowni danych udowodnił kluczowe znaczenie warstwy przejściowej (*Staging Area*) oraz mechanizmów czyszczenia i walidacji danych tekstowych. Zaimplementowanie kaskadowych transformacji *Lookup* oraz zaawansowanego komponentu wyszukiwania rozmytego (*Fuzzy Lookup*) pozwoliło na pełną standaryzację poziomów polis i profili społeczno-zawodowych klientów. Z kolei zastosowanie mechanizmu miękkiego przechwytywania błędów (*Redirect Row*) na poziomie rzutowania typów danych zabezpieczyło strukturę przed awariami transakcyjnymi, gwarantując bezstratne i powtarzalne ładowanie miliona wierszy bezpośrednio do docelowego schematu gwiazdy.

Warstwa Semantyczna i Logika MDX (SSAS): Projektowanie wielowymiarowej kostki OLAP pozwoliło na prekompilację i agregację surowych faktów ubezpieczeniowych, całkowicie uniezależniając system od konieczności wykonywania kosztownych obliczeń po stronie aplikacji klienckich. Wdrożenie miar obliczanych w języku MDX (Avg Charges, Avg BMI, Avg Age) oraz wielopoziomowych hierarchii analitycznych dało menedżerom możliwość błyskawicznego drążenia danych (*drill-down*) w ujęciu geograficznym i demograficznym. Implementacja czterech strategicznych wskaźników KPI wyposażała przedsiębiorstwo w inteligentny system wczesnego ostrzegania przed stratami finansowymi.

Warstwa Eksploracji Danych i AI (Data Mining): Wykorzystanie trzech konkurujących ze sobą algorytmów uczenia maszynowego (*Microsoft Decision Trees*, *Microsoft Clustering*, *Microsoft Neural Network*) pozwoliło na przejście od raportowania retrospektywnego do zaawansowanej analityki predykcyjnej. Modele matematycznie udowodniły, że najsilniejszym faktorem determinującym krytyczny wzrost kosztów medycznych jest nałóg tytoniowy skorelowany z otyłością ($BMI > 30$) oraz zaawansowanym wiekiem. Eksport wyników predykcji bezpośrednio do tabel relacyjnych bazy danych oraz ich ponowna integracja z tabelą faktów pozwoliły na bezpośrednią walidację skuteczności sztucznej inteligencji na dashboardach raportowych.

Warstwa Prezentacji i Wizualizacji (Power BI): Stworzenie czterech interaktywnych, połączonych na żywo (*Connect Live*) pulpitów menedżerskich dostarczyło unikalnego narzędzia analitycznego. Zastosowanie wykresów punktowych rozrzutu, macierzy z mapami cieplnymi, wykresów lejkowych oraz kaskadowych pozwoliło na zwizualizowanie skomplikowanych zależności statystycznych w sposób prosty i intuicyjny dla odbiorcy biznesowego. Na szczególne wyróżnienie zasługuje panel walidacji modeli AI dla przedziału wiekowego 18-41 lat, który wprost wykazał, że algorytm sieci neuronowej oraz drzew decyzyjnych charakteryzuje się najwyższą precyzją prognozowania kosztów i idealnie pokrywa się z krzywą kosztów rzeczywistych.

